# Дифракционная нейронная сеть (D2NN)

## Оптическая реализация нейронной сети

**Акинжала Родион**

Московский физико-технический институт

ФПМИ ПМФ: Углубленный анализ данных

*Группа Б05-303*

# Введение

**Проблема:** Традиционные нейросети требуют значительных энергозатрат и вычислительных ресурсов, что ограничивает масштабируемость для задач обработки данных в реальном времени.

**Решение — оптические вычисления:**

- Энергоэффективность (исключение электронных потерь)
- Пропускная способность на уровне скорости света

**D2NN (Diffractive Deep Neural Network):**
Оптическая реализация нейросети через архитектуру фазовых модуляторов и свободного распространения света. Фазовые слои кодируют параметры модели, распространение реализует нелинейную трансформацию данных.

**Цель:** Анализ практической реализации и устойчивости D2NN.

# Архитектура D2NN

D2NN состоит из:

- $N$ плоских фазовых масок
- Разделены промежутками свободного распространения
- На выходе — пространственное распределение интенсивности и детектор

**Операции каждого слоя:**

1. Фазовая модуляция
2. Свободное дифракционное распространение

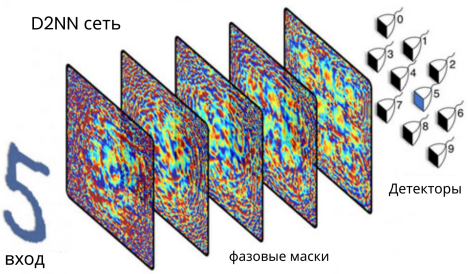



*Схема установки*

# Физическая модель

Каждый фазовый слой $m$ описывается фазовой функцией $\varphi_m(x, y)$ и реализует преобразование:

$$A_m^+(x, y) = A_m(x, y) \cdot e^{i\varphi_m(x,y)}$$

где $A_m(x, y)$ — поле *перед* маской, $A_m^+(x, y)$ — поле *после*.

**Результирующее преобразование:**

- Каждый слой: фазовая модуляция
- Промежуток между слоями: свободное дифракционное распространение
- Эквивалент весовых коэффициентов в традиционной нейросети

# Волновое уравнение Гельмгольца

Монохроматическое волновое поле описывается комплексной амплитудой:

$$E(\mathrm{r}, t) = \Re\{A(x, y, z)e^{-i\omega t}\}$$

Амплитуда в однородной среде удовлетворяет уравнению Гельмгольца:

$$\nabla^2 A + k^2 A = 0, \quad k = \frac{2\pi n}{\lambda}$$

Решение представляется суперпозицией плоских волн. Для волны $e^{i(k_x x + k_y y)}$ продольная компонента волнового вектора:

$$k_z = \sqrt{k^2 - k_x^2 - k_y^2}$$

# Метод Рэлея: распространение углового спектра

**Шаг 1. Преобразование Фурье в плоскости $z = 0$:**

$$\tilde{A}(k_x, k_y; 0) = \iint A(x, y, 0)\, e^{-i(k_x x + k_y y)}\, dx\, dy$$

**Шаг 2. Фазовый набег при распространении на расстояние $z$:**

$$\tilde{A}(k_x, k_y; z) = \tilde{A}(k_x, k_y; 0) \cdot e^{ik_z z}$$

**Шаг 3. Обратное преобразование Фурье:**

$$A(x, y, z) = \frac{1}{(2\pi)^2} \iint \tilde{A}(k_x, k_y; z)\, e^{i(k_x x + k_y y)}\, dk_x\, dk_y$$

Численно реализуется с помощью быстрого преобразования Фурье (FFT)

# Архитектура D2NN

**Математическая формулировка:**

$$A_{\text{out}} = \mathcal{P}_{d_N} \circ e^{i\varphi_N} \circ \mathcal{P}_{d_{N-1}} \circ \cdots \circ e^{i\varphi_1} \circ \mathcal{P}_{d_1}\{A_{\text{in}}\}$$

где $\mathcal{P}_d$ — оператор свободного распространения (метод Рэлея), $e^{i\varphi_m}$ — фазовая модуляция на слое $m$.

**Выходной сигнал:**

$$I(x, y) = |A_{\text{out}}(x, y)|^2$$

Детектор регистрирует пространственное распределение интенсивности и преобразует его в вектор классификационных оценок (логиты).

**Параметры модели:** Фазовые профили $\{\varphi_1, \ldots, \varphi_N\}$ — обучаемые параметры, эквивалентные весам традиционной нейросети. Расстояния между слоями $\{d_1, \ldots, d_{N-1}\}$ — фиксированные геометрические параметры.

# Обучение

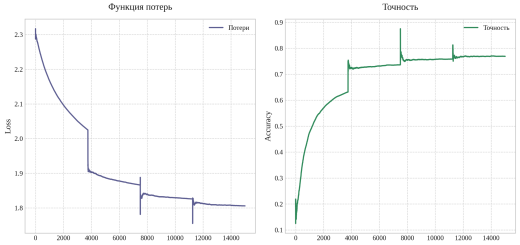
**Функция потерь:**

$$\mathcal{L} = -\sum_{k=1}^{C} y_k \log(p_k)$$

где $y_k$ — one-hot закодированный истинный класс, $p_k$ — предсказанная вероятность через softmax от логитов детектора.

**Процесс обучения:**

1. Детектор выдает логиты: $\text{logit}_k = \text{mean}(|A_{\text{out}}|^2)$ в регионе $k$
2. Softmax преобразует в вероятности
3. Adam оптимизатор обновляет фазовые профили $\{\varphi_1, \ldots, \varphi_N\}$




Динамика потерь и точности на валидации

# Инициализация фазовых масок: алгоритм Гершберга-Сакстона

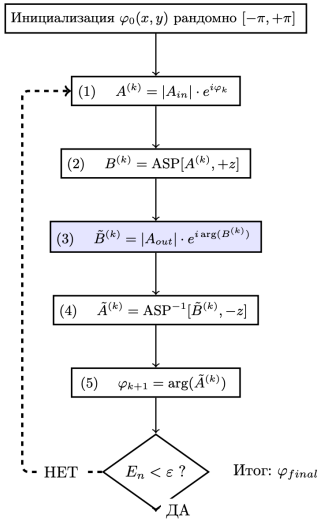
**Мотивация:**
Вместо инициализации $\varphi_m \sim \mathcal{U}[-\pi, \pi]$, использовать физически осмысленное начальное приближение.

**Функция потерь:**

$$E^{(k)} = \sum_{x,y} \left| |B^{(k)}(x,y)| - |A_{\text{target}}(x,y)| \right|^2$$

**Целевое распределение:**
Гауссиан обеспечивает концентрацию энергии в центре:

$$A_{\text{target}} = \exp\left(-\frac{x^2+y^2}{2\sigma^2}\right)$$



# Сходимость построения масок

**Два домена, связанные ASP:**

- Домен 1: маска $\varphi_k(x, y)$
- Домен 2: поле на выходе $B^{(k)}(x, y)$

**На каждой итерации:**

Коррекция амплитуды в домене 2:

$$c_{\text{out}} = |A_{\text{target}}| - |B^{(k)}|$$

Обратное распространение передает коррекцию в фазу маски:

$$\varphi_{k+1} = \arg\left(\text{ASP}^{-1}[\cdot, -z]\right)$$

**Теорема Парсеваля:**

Энергия коррекции сохраняется:

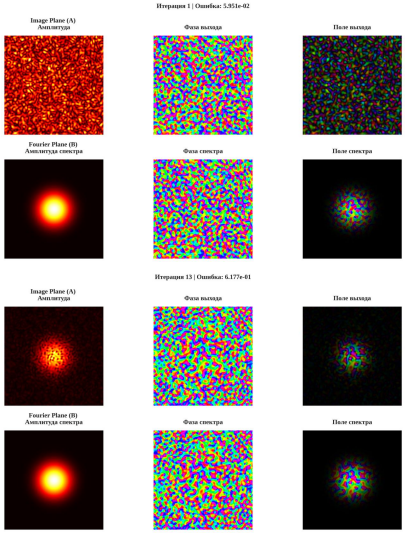
$$\sum |c_{\text{out}}|^2 = \sum |c_{\text{mask}}|^2$$

Поэтому ошибка монотонно убывает:

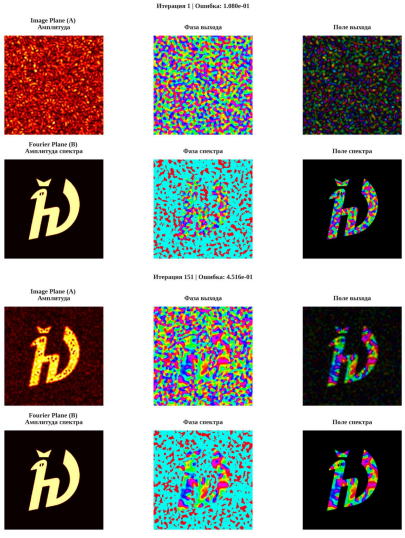
$$\boxed{E^{(k+1)} \leq E^{(k)}}$$

Гарантированная сходимость к оптимальной маске

# Эволюция алгоритма Гершберга-Сакстона



# Эволюция алгоритма Гершберга-Сакстона



# Влияние инициализации на обучение

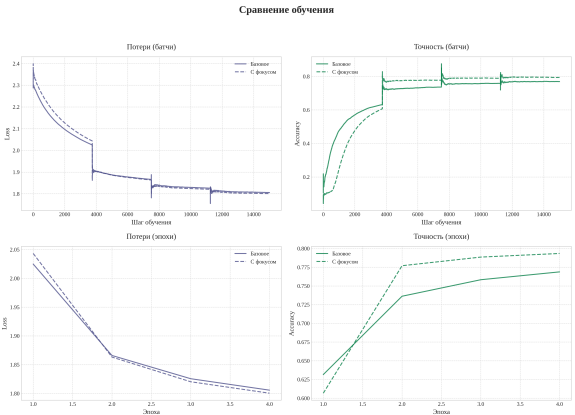
**Две стратегии инициализации:**

1. **Random:** $\varphi_m \sim \mathcal{U}[-\pi, \pi]$
   Случайная фаза без физического смысла

2. **G-S Init:** Фазовые маски оптимизированы алгоритмом Гершберга-Сакстона
   Каждая маска уже действует как фокусирующая линза

**Результат:** G-S инициализация:

- Ускорила сходимость обучения (меньше эпох)
- Точность выше



# Фазовые слои

**Толщина:**

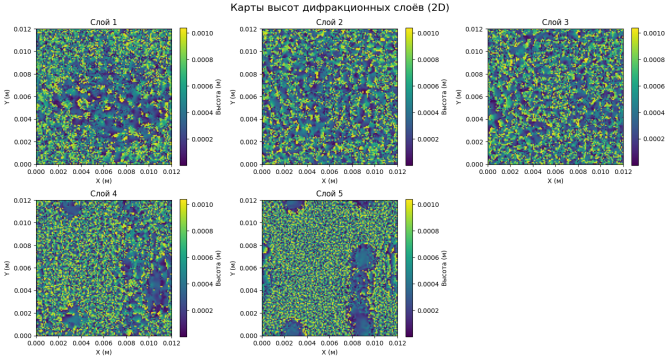
Фазовые профили кодируют информацию модели. Для физической можно рассчитать толщину:

$$h(x, y) = \frac{\lambda\, \Phi(x, y)}{2\pi(\Delta n)}$$

**Система параметров:**

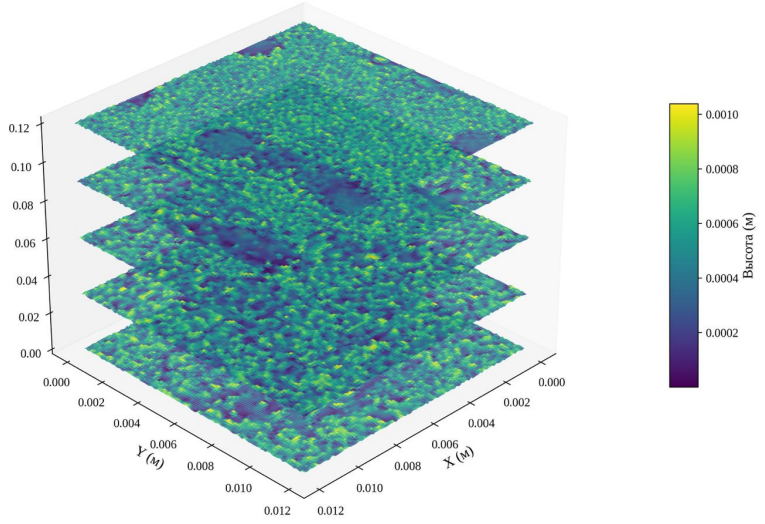
| | |
|---|---|
| Длина волны | $\lambda = 0.75$ мм |
| Показатель (материал) | $n_{\mathrm{mat}} = 1.7227$ |
| Показатель (воздух) | $n_{\mathrm{air}} = 1.0003$ |

Материал: фотополимер VeroBlackPlus RGD875



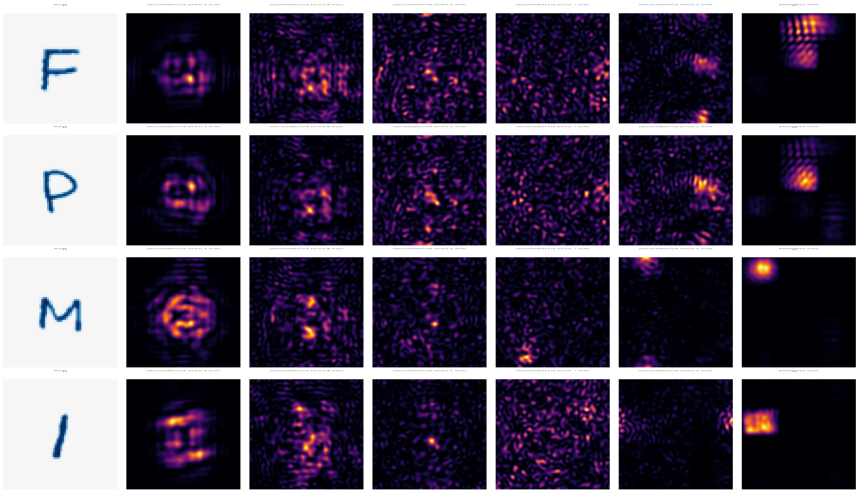

Проекции фазовых профилей каждого слоя

# Фазовые слои




Фазовые слои D2NN

# Эволюция интенсивности вдоль оптической оси



Распределение интенсивности $I(x, y)$ после каждого слоя

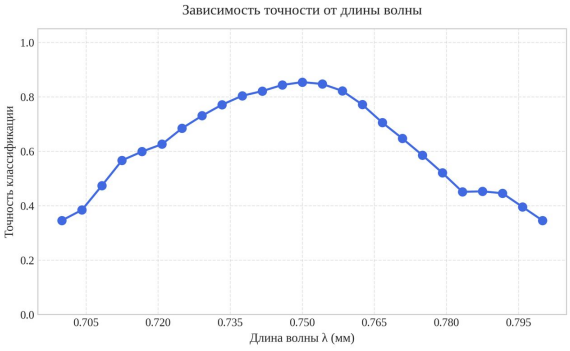
# Анализ устойчивости: длина волны

**Задача:** Определить допустимые отклонения физических параметров без потери точности

**Результаты:**

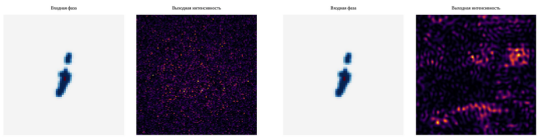
- Обучение: $\lambda = 0.75$ мм
- Тестирование: $\lambda$ в диапазоне $\pm 2\%$
- Точность остается выше 80%

**Вывод:** Система устойчива к спектральным флуктуациям источника

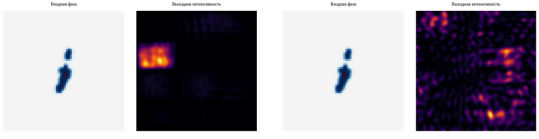



*Зависимость точности от $\lambda$*

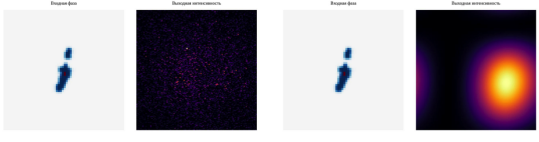
# Анализ устойчивости: длина волны




$\lambda = 0.1 \cdot 10^{-3}\,\mathrm{m}$ $\lambda = 0.6 \cdot 10^{-3}\,\mathrm{m}$




$\lambda = 0.75 \cdot 10^{-3}\,\mathrm{m}$ (исходное значение) $\lambda = 0.9 \cdot 10^{-3}\,\mathrm{m}$




$\lambda = 0.9 \cdot 10^{-4}\,\mathrm{mm}$ $\lambda = 0.75 \cdot 10^{-1}\,\mathrm{mm}$

Распределение интенсивности на детекторе

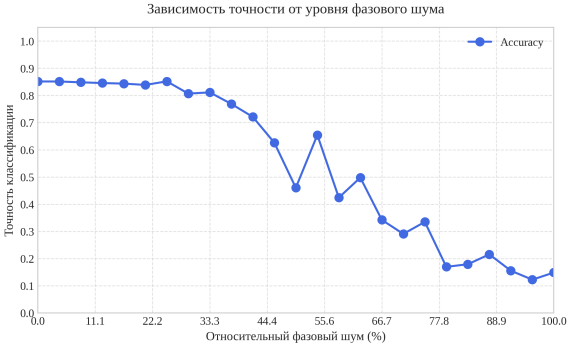
# Анализ устойчивости: фазовый шум

**Модель шума:**
Нормально распределённые возмущения фазовых профилей

$$\delta(x, y) \sim \mathcal{N}\left(0,\, \sigma^2(x, y)\right)$$

$$\sigma = \alpha \cdot |\varphi(x, y)|$$

где $\alpha \in [0, 1]$ — параметр уровня шума.




*Точность при разных уровнях шума*

# Выводы

**D2NN — оптическая реализация нейросети:**

- Фазовые маски как обучаемые параметры модели
- Дифракционное распространение (ASP) как нелинейная трансформация

**Инициализация G-S:**

- Физически осмысленные начальные условия вместо случайных
- Гарантированная сходимость, ускорение обучения

**Робастность и применение:**

- Устойчивость к вариациям: $\pm 2\%$ по $\lambda$, допуск на фазовый шум
- Реализуемость на современной 3D-печати, энергоэффективность

# Спасибо за внимание!

*Акинжала Родион*
Группа Б05-303